

**PREDIKSI FREKUENSI, SEVERITAS, DAN TOTAL KLAIM ASURANSI
KESEHATAN PERIODE AGUSTUS 2025–DESEMBER 2026
MENGUNAKAN PENDEKATAN *ENSEMBLE TIME-SERIES* MODEL
BERBASIS AGREGASI MINGGUAN**



Tim—hmm ywd gas

1st Robben Wijanathan
Binus University
Jakarta, Indonesia

2nd Jovan Melsyah
Binus University
Jakarta, Indonesia

3rd Bryan Yiling
Binus University
Jakarta, Indonesia

**DATA SCIENCE COMPETITION
MATHEMATICAL CHALLENGE FESTIVAL
INSTITUT TEKNOLOGI BANDUNG
2026**

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim : hmm ywd gas
Nama Ketua Tim : Robben Wijanathan
Nama Anggota Tim 1 : Jovan Melsyah
Nama Anggota Tim 2 : Bryan Yiling

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan Data Science Competition MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model : ChatGPT 5.2, Gemini 3, Claude Sonnet 4.5
Pengembang Model : OpenAI, Google, Anthropic

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

ChatGPT digunakan untuk mendukung proses riset literatur, eksplorasi konsep, penjelasan metodologi, brainstorming ide, serta membantu dalam review dan evaluasi kode program; Claude digunakan dalam penyusunan dan penyempurnaan laporan, serta asisten dalam dokumentasi teknis dan penjelasan metodologi; Gemini digunakan untuk membantu dalam visualisasi dan analisis data, interpretasi hasil, asisten pembuatan code, serta perumusan ringkasan temuan berbasis data.

Kami menyatakan bahwa seluruh keluaran model model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi dari

perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Jakarta, Februari 2026

Yang menyatakan,

A handwritten signature in black ink, consisting of stylized, overlapping loops and a long horizontal stroke extending to the right.

Robben Wijanathan

Abstrak

Abstrak—Peningkatan klaim asuransi kesehatan individu sebesar 25,5% pada paruh pertama 2025 mendorong pembangunan model prediktif untuk memproyeksikan frekuensi (N_t), total (S_t), dan severitas klaim (Z_t) periode Agustus 2025–Desember 2026 (17 bulan). Dari 4.627 transaksi *paid* (Januari 2024–Juli 2025), data diagregasi mingguan (83 observasi), lalu diproses melalui *winsorization* dan transformasi logaritmik. Sepuluh model dievaluasi dengan *walk-forward validation* (MAPE). LightGBM mencatatkan performa terbaik secara individual (MAPE 6,64%), sementara pendekatan *ensemble blend* tujuh model dengan komponen *Seasonal Naïve* (80:20) menghasilkan MAPE terbaik sebesar **6,22%**. Lokasi rumah sakit (klaim Singapura $3,7\times$ lebih mahal) dan tipe perawatan (rawat inap: 74% total nilai) menjadi determinan utama severitas. Proyeksi akhir memperkirakan total klaim rata-rata IDR 11,8 miliar/bulan (2025) dan IDR 10,7 miliar/bulan (2026).

Kata Kunci—Asuransi Klaim Kesehatan, *Time-Series Forecasting*, *Frequency–Severity Framework*, *Ensemble Blending*, *Walk-Forward Validation*, LightGBM, DLinear, *Seasonal Naïve*.

Daftar Isi

1	Pendahuluan	6
1.1	Latar Belakang	6
1.2	Rumusan Masalah	7
1.3	Tujuan Penelitian	7
1.4	Ruang Lingkup dan Batasan Studi	7
2	Tinjauan Pustaka dan Metodologi	8
2.1	Deskripsi Dataset	8
2.2	Formulasi Masalah	8
2.3	Data Cleaning dan Missing Values	9
2.4	Feature Engineering & Transformasi Data	9
2.4.1	Lag Features	9
2.4.2	Logarithmic Transformation (Log-Scaling)	9
2.5	Agregasi Time-Series	10
2.6	Model yang Digunakan	10
2.6.1	Model Baseline	10
2.6.2	Model Statistik Klasik	11
2.6.3	Gradient Boosting	11
2.6.4	Linear Decomposition	11
2.7	Ensemble Learning & Model Blending	11
2.8	Time-Based Cross Validation	12
2.8.1	Walk-Forward Validation (Rolling Forecast)	12
2.8.2	Metrics	12
3	Hasil dan Pembahasan	13
3.1	Exploratory Data Analysis	13
3.2	Model Training	17
3.3	Evaluasi Model	17
3.4	Hasil Prediksi Agustus–Desember 2025	18
3.5	Hasil Prediksi Januari–Desember 2026	19
4	Penutup	20
4.1	Kesimpulan	20
4.2	Rekomendasi Strategis untuk Perusahaan	20

Daftar Pustaka	21
Lampiran	23
Source Code	23

Daftar Gambar

1	Tabel Data Klaim	8
2	Tabel Data Polis	8
3	Deret Waktu Total Klaim Mingguan Sebelum dan Sesudah <i>Winsorization</i> dan Transformasi Logaritmik	10
4	Tren Bulanan Data Klaim Januari 2024–Juli 2025	13
5	Tren Mingguan Frekuensi dan Total Klaim	13
6	Pola Rata-Rata Bulanan Gabungan Dua Tahun Observasi	14
7	Distribusi Klaim Berdasarkan Hari Masuk Rumah Sakit	14
8	<i>Heatmap</i> Frekuensi dan Severitas per Tahun dan Bulan	14
9	Analisis Distribusi Nilai Klaim Individual	15
10	Analisis Jenis Klaim Berdasarkan Tipe Perawatan dan Metode Pembayaran . .	15
11	Analisis Geografis Berdasarkan Lokasi Rumah Sakit	15
12	Analisis Severitas dan Deteksi Outlier	16
13	Perbandingan <i>year-over-year</i> 2024 vs. 2025 (Januari–Juli)	16
14	Rasio Bulanan 2025/2024 untuk Data Klaim	16
15	<i>Walk-Forward</i> CV MAPE per Model	18
16	Proyeksi Data Klaim Periode Agustus 2025–Desember 2026	19

Daftar Tabel

1	Sampel Matriks <i>Lag Features</i> ($k=4$, Dimensi 79×5)	9
2	Sampel Agregasi Mingguan dan Bulanan	10
3	Konfigurasi <i>Walk-Forward Validation</i>	12
4	Konfigurasi Model yang Digunakan	17
5	Perbandingan MAPE <i>Walk-Forward</i> (Rata-Rata 5 Bulan Uji)	17
6	Bobot <i>Ensemble</i> dan Hasil <i>Backtest</i> Maret–Juli 2025	18
7	Proyeksi Data Klaim Agustus–Desember 2025	18
8	Proyeksi Data Klaim Januari–Desember 2026	19

I. Pendahuluan

1.1 Latar Belakang

Asuransi kesehatan individu merupakan salah satu instrumen perlindungan finansial terhadap risiko kesehatan yang tidak terduga, seperti penyakit atau kecelakaan, yang berpotensi menimbulkan biaya besar dan berdampak pada perencanaan keuangan pribadi.¹ Industri asuransi memainkan peran krusial dalam melindungi individu maupun pelaku usaha, sekaligus memberikan kontribusi nyata terhadap stabilitas ekonomi. Dalam operasionalnya, perusahaan asuransi wajib memiliki dana yang cukup untuk memenuhi seluruh kewajiban polis yang aktif, termasuk klaim yang akan datang.

Salah satu isu yang berkembang dalam beberapa tahun terakhir adalah **peningkatan klaim asuransi kesehatan individu yang signifikan**. Tercatat terjadi kenaikan sebesar **25,5%** antara periode Januari–Juni 2025 dibandingkan periode yang sama di tahun 2024. Peningkatan ini berpotensi mendorong penyesuaian premi yang dapat menjadikan produk asuransi kesehatan individu semakin tidak terjangkau bagi masyarakat luas. Oleh karena itu, diperlukan analisis berbasis data untuk memprediksi faktor-faktor yang paling berpengaruh terhadap nilai klaim, sehingga dapat dilakukan inisiatif dari segi seleksi risiko, pencegahan, maupun deteksi dini guna meminimalkan dampak peningkatan klaim.

Seiring dengan pesatnya perkembangan teknologi dan meningkatnya volume data, metode *machine learning* (ML) telah menunjukkan potensi besar dalam mengidentifikasi hubungan antarvariabel serta menghasilkan prediksi yang lebih akurat.¹¹ Distribusi nilai klaim yang cenderung sangat *right-skewed* menyebabkan **pendekatan statistik tradisional rentan menghasilkan estimasi yang tidak akurat**, sehingga berdampak pada penetapan premi dan kecukupan cadangan teknis perusahaan.

Penelitian ini dilaksanakan dalam konteks *Data Science Competition 2026 – MCF ITB*, di mana peserta ditugaskan untuk: (i) mengeksplorasi dan membersihkan data klaim, (ii) mengidentifikasi faktor-faktor yang paling memengaruhi frekuensi dan severitas klaim, serta (iii) membangun dan mengevaluasi model *machine learning* untuk memproyeksikan tren frekuensi, severitas, dan total klaim periode **Agustus 2025 hingga Desember 2026** berdasarkan data historis Januari 2024–Juli 2025. Cakupan proyeksi 17 bulan ke depan menuntut model yang tidak hanya akurat pada jangka pendek, tetapi juga mampu mempertahankan performa pada horizon yang lebih panjang dengan data latih yang terbatas.

1.2 Rumusan Masalah

1. Bagaimana karakteristik dan pola historis data klaim kesehatan periode Januari 2024–Juli 2025?
2. Faktor apa yang paling memengaruhi frekuensi dan severitas klaim?
3. Model prediktif apa yang paling akurat untuk memproyeksikan frekuensi, severitas, dan total klaim bulanan?
4. Bagaimana hasil proyeksi klaim periode **Agustus 2025–Desember 2026**?

1.3 Tujuan Penelitian

1. Mengeksplorasi data dan mengidentifikasi faktor yang memengaruhi frekuensi dan severitas klaim asuransi kesehatan.
2. Menentukan strategi *preprocessing* dan rekayasa fitur yang sesuai dengan karakteristik data yang tersedia.
3. Membangun dan mengevaluasi model *machine learning* untuk memproyeksikan frekuensi, severitas, dan total klaim bulanan.
4. Menghasilkan proyeksi klaim periode **Agustus 2025–Desember 2026**.

1.4 Ruang Lingkup dan Batasan Studi

1. Target peramalan berupa frekuensi, severitas, dan total klaim agregat portofolio untuk periode **Agustus 2025–Desember 2026** (17 bulan).
2. Data pelatihan dibatasi pada **4.627 transaksi berstatus PAID** periode Januari 2024–Juli 2025.
3. Fitur demografis polis hanya digunakan pada tahap EDA dan **tidak diikutsertakan** sebagai prediktor pemodelan.
4. Model berbasis pola historis tanpa variabel eksternal seperti inflasi medis atau kebijakan asuransi.

II. Tinjauan Pustaka dan Metodologi

2.1 Deskripsi Dataset

Penelitian ini menggunakan dua dataset: **Data_Klaim** (transaksi klaim) dan **Data_Polis** (profil pemegang polis), yang dapat dihubungkan melalui *Nomor Polis*.

Claim ID	Nomor Polis	Reimburse/C	Inpatient/Outpatient	ICD Diagnosis	ICD Description	Status Klaim	Tanggal Pemohonan	Tanggal Pasi	Tanggal Pasi	Nominal Klaim	Nominal Biaya	Lokasi RS
C-0001-M	POL-0176	R	OP	C50	MALIGNANT	PAID	08/07/2024	27/05/2024	27/05/2024	28093653	6143947.68	Singapore
C-0002-M	POL-3288	R	OP	C34	MALIGNANT	PAID	06/08/2024	15/07/2024	15/07/2024	80987278	82309522.45	Malaysia
C-0003-M	POL-1786	R	OP	C18.9	MALIGNANT	PAID	17/10/2024	16/05/2024	16/05/2024	183047130	192859905	Singapore
C-0004-M	POL-1786	R	OP	C34	MALIGNANT	PAID	03/09/2024	18/07/2024	18/07/2024	191424386	191424385.7	Singapore
C-0005-M	POL-2778	R	OP	C50	MALIGNANT	PAID		06/06/2024	06/06/2024	138936357	138936357	Singapore

Gambar 1: Tabel Data Klaim

Data_Klaim memuat 4.627 transaksi berstatus *paid* periode Januari 2024–Juli 2025. Setiap record mencakup identitas klaim, jenis perawatan, diagnosis (ICD), lokasi rumah sakit, metode pembayaran, tiga variabel tanggal, dan nominal klaim. Tanggal masuk rumah sakit digunakan sebagai acuan agregasi temporal. Distribusi nilai klaim sangat *right-skewed* (skewness = 6,64); 10% klaim terbesar menyumbang lebih dari 60% total nilai. Data diagregasi ke granularitas **mingguan** (83 titik) untuk menghindari *data starvation* yang terjadi pada agregasi bulanan (hanya 19 titik).

Claim ID	Nomor Polis	Reimburse/C	Inpatient/Outpatient	ICD Diagnosis	ICD Description	Status Klaim	Tanggal Pemohonan	Tanggal Pasi	Tanggal Pasi	Nominal Klaim	Nominal Biaya	Lokasi RS
C-0001-M	POL-0176	R	OP	C50	MALIGNANT	PAID	08/07/2024	27/05/2024	27/05/2024	28093653	6143947.68	Singapore
C-0002-M	POL-3288	R	OP	C34	MALIGNANT	PAID	06/08/2024	15/07/2024	15/07/2024	80987278	82309522.45	Malaysia
C-0003-M	POL-1786	R	OP	C18.9	MALIGNANT	PAID	17/10/2024	16/05/2024	16/05/2024	183047130	192859905	Singapore
C-0004-M	POL-1786	R	OP	C34	MALIGNANT	PAID	03/09/2024	18/07/2024	18/07/2024	191424386	191424385.7	Singapore
C-0005-M	POL-2778	R	OP	C50	MALIGNANT	PAID		06/06/2024	06/06/2024	138936357	138936357	Singapore

Gambar 2: Tabel Data Polis

Data_Polis memuat profil 4.096 pemegang polis aktif. Seluruh polis telah aktif sejak sebelum periode observasi tanpa perubahan, sehingga eksposur E_t konstan dan data polis hanya digunakan pada tahap EDA—**tidak diikutsertakan** sebagai prediktor.

2.2 Formulasi Masalah

Total klaim didekomposisi melalui *frequency–severity framework* menjadi tiga target prediksi:

- **Frekuensi** (N_t): jumlah klaim pada periode t . Karena E_t konstan, N_t digunakan langsung tanpa normalisasi eksposur.
- **Severitas** (Z_t): rata-rata nilai klaim per periode,

$$Z_t = \frac{S_t}{N_t}$$

Tidak dimodelkan langsung, melainkan diturunkan dari hasil prediksi N_t dan S_t .

- **Total Klaim (S_t):**

$$S_t = N_t \times Z_t$$

N_t dan S_t dimodelkan terpisah pada granularitas mingguan, kemudian diagregasi ke level bulanan melalui *day-fraction rollup*.

2.3 Data Cleaning dan Missing Values

Seluruh klaim berstatus *non-paid* dieksklusi sehingga dataset final hanya mencakup transaksi yang merepresentasikan beban finansial aktual. *Missing values* yang ditemukan berjumlah terbatas—Inpatient/Outpatient (37), ICD Diagnosis/ Description (6), dan Lokasi RS (7)—diisi dengan label "Unknown" untuk keperluan EDA dan tidak memengaruhi pemodelan karena kolom tersebut tidak digunakan sebagai prediktor.

2.4 Feature Engineering & Transformasi Data

2.4.1 Lag Features

Lag features mengubah deret waktu $\{y_t\}$ menjadi matriks regresi *supervised* dengan *look-back k*:

$$\mathbf{x}_t = [y_{t-k}, y_{t-k+1}, \dots, y_{t-1}] \quad (1)$$

Dengan $k=4$ pada 83 titik mingguan, dihasilkan matriks 79×5 . Nilai k optimal per model ditentukan via *grid search CV*.

Table 1: Sampel Matriks *Lag Features* ($k=4$, Dimensi 79×5)


Idx	lag_1	lag_2	lag_3	lag_4	y
0	46,0	84,0	95,0	48,0	51,0
1	84,0	95,0	48,0	51,0	33,0
2	95,0	48,0	51,0	33,0	44,0
			$\vdots$		

2.4.2 Logarithmic Transformation (Log-Scaling)

Total klaim mingguan bersifat sangat *right-skewed* ($CV = 0,43$; $skewness = 1,12$). Diterapkan *winsorization* pada $\mu \pm 2,5\sigma$ diikuti transformasi logaritmik:

$$\tilde{S}_t = \ln(\max(S_t, 1)) \quad (2)$$

Hasilnya CV turun ke 0,20 dan skewness menjadi $-0,46$. Prediksi dikembalikan ke skala asli via $\hat{S}_t = e^{\tilde{S}_t}$.



Gambar 3: Deret Waktu Total Klaim Mingguan Sebelum dan Sesudah *Winsorization* dan Transformasi Logaritmik

2.5 Agregasi Time-Series

Data diagregasi ke dua level: **mingguan** sebagai basis pemodelan (83 titik) dan **bulanan** sebagai target evaluasi (19 titik).

Table 2: Sampel Agregasi Mingguan dan Bulanan

Mingguan (83 baris)				Bulanan (19 baris)			
Idx	Periode	Freq	Total (IDR)	Idx	Tanggal	Freq	Total (IDR)
78	30 Jun–06 Jul	53	4,38M	13	2025-02-01	246	17,48B
79	07–13 Jul	62	2,98M	14	2025-03-01	230	13,68B
80	14–20 Jul	58	2,04M	15	2025-04-01	208	11,16B
		⋮				⋮	

Konversi mingguan ke bulanan menggunakan *day-fraction rollout*: setiap hari berkontribusi nilai/7 ke bulan yang bersangkutan, menangani minggu parsial secara proporsional.

2.6 Model yang Digunakan

Penelitian ini menguji sepuluh arsitektur model dalam empat kategori. N_t dan $\ln(S_t)$ dimodelkan secara terpisah sebagai fungsi historisnya sendiri (*univariate autoregressive*).

2.6.1 Model Baseline

Naïve memproyeksikan nilai berikutnya sama dengan nilai terakhir yang diamati. **Seasonal Naïve** memproyeksikan berdasarkan nilai periode yang sama tahun sebelumnya dika-

likan rasio YoY median. Keduanya berfungsi sebagai acuan minimum perbandingan performa.

2.6.2 Model Statistik Klasik

SES memberikan bobot eksponensial menurun pada observasi historis dengan α dioptimasi via SSE, cocok untuk deret tanpa tren kuat. **ARIMA**(1, 1, 0) memodelkan diferensi pertama secara autoregresif orde satu. **Auto-SARIMA** memperluas ARIMA dengan komponen musiman menggunakan seleksi orde otomatis *stepwise* ($m=4$).² **Theta Model** mendekomposisi deret menjadi dua *theta line* ($\theta=0$ untuk tren; $\theta=2$ untuk fluktuasi jangka pendek) lalu menggabungkan keduanya sebagai prediksi akhir.²

2.6.3 Gradient Boosting

LightGBM memodelkan deret waktu sebagai regresi *supervised* dengan $lag = 12$ sebagai fitur input dan 200 estimator. Struktur *tree-based*-nya mampu menangkap hubungan nonlinier kompleks yang sulit dijangkau model statistik klasik.⁸

2.6.4 Linear Decomposition

NLinear menormalisasi deret dengan mengurangi nilai terakhir sebelum melewati lapisan linier, sehingga model fokus pada perubahan relatif. **DLinear** mendekomposisi deret menjadi komponen tren dan residual via *moving average*, lalu memodelkan keduanya secara terpisah. **MultiDLinear** menggabungkan beberapa *lookback window* ($lb \in \{4, 8, 12, 16\}$) secara paralel untuk menangkap dependensi pada berbagai skala temporal sekaligus.

Kami sengaja membatasi pendekatan *deep learning* pada dua arsitektur berbasis linier ini dan tidak mengadopsi model berbasis Transformer. Keputusan ini didasarkan pada temuan yang menunjukkan bahwa model Transformer, meskipun populer, tidak lebih efektif dibandingkan model linier sederhana untuk permasalahan *long-term time series forecasting*.¹⁵ Mengikuti kesimpulan tersebut, kami memprioritaskan kesederhanaan dan interpretabilitas model tanpa mengorbankan akurasi prediksi.

2.7 Ensemble Learning & Model Blending

Prediksi akhir dihasilkan melalui dua lapis penggabungan. Pertama, tujuh model digabungkan dengan bobot invers MAPE:

$$w_m = \frac{1/\text{MAPE}_m}{\sum_j 1/\text{MAPE}_j} \quad (3)$$

Kedua, hasil *ensemble* dicampur dengan *Seasonal Naïve* (nilai bulan sama tahun lalu $\times$ rasio YoY median) dengan rasio 80:20:

$$\hat{y}_t = 0,8 \cdot \hat{y}_t^{\text{ens}} + 0,2 \cdot \hat{y}_t^{\text{sn}} \quad (4)$$

Komponen *Seasonal Naïve* berfungsi sebagai *anchor* musiman untuk mengimbangi keterbatasan model deret waktu pada jendela historis yang pendek.

2.8 Time-Based Cross Validation

2.8.1 Walk-Forward Validation (Rolling Forecast)

Evaluasi menggunakan *walk-forward validation* untuk menghindari *data leakage*: model dilatih pada seluruh data sebelum bulan uji, lalu diuji satu bulan ke depan—diulang untuk 5 bulan terakhir.

Table 3: Konfigurasi *Walk-Forward Validation*

Fold	Bulan Uji	Data Latih	Minggu Latih
1	Maret 2025	Jan 2024 – Feb 2025	61
2	April 2025	Jan 2024 – Mar 2025	65
3	Mei 2025	Jan 2024 – Apr 2025	69
4	Juni 2025	Jan 2024 – Mei 2025	74
5	Juli 2025	Jan 2024 – Jun 2025	78

2.8.2 Metrics

Metrik evaluasi yang digunakan adalah MAPE:


$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100\% \quad (5)$$

MAPE dihitung terpisah untuk N_t , Z_t , dan S_t , lalu dirata-ratakan menjadi satu nilai *overall*. Nilai Z_t diturunkan dari $\hat{S}_t / \hat{N}_t$, bukan dimodelkan langsung.

III. Hasil dan Pembahasan


3.1 Exploratory Data Analysis

Exploratory Data Analysis dilakukan pada data agregasi bulanan dan mingguan dari 4.627 transaksi periode Januari 2024–Juli 2025.



Gambar 4: Tren Bulanan Data Klaim Januari 2024–Juli 2025


Frekuensi stabil di sekitar 244 klaim/bulan. Severitas bersifat *mean-reverting* (rata-rata IDR 55,1 juta) dengan anomali ekstrem pada Februari 2025 (IDR 71,1 juta, $> +2\sigma$) yang mendominasi total klaim bulan tersebut (IDR 17,5 miliar).



Gambar 5: Tren Mingguan Frekuensi dan Total Klaim


Pada resolusi mingguan, satu minggu Februari 2025 mencapai IDR 7,9 miliar— $2,5\times$ di

atas rata-rata dan menjadi outlier terbesar dalam keseluruhan data.




Gambar 6: Pola Rata-Rata Bulanan Gabungan Dua Tahun Observasi

Frekuensi cenderung lebih tinggi pada Oktober–November. Severitas meningkat pada awal tahun (Jan–Feb) dan pertengahan tahun (Jun–Jul). Pola ini menjadi landasan komponen *Seasonal Naïve* dalam *ensemble*.




Gambar 7: Distribusi Klaim Berdasarkan Hari Masuk Rumah Sakit

Klaim terkonsentrasi pada hari kerja ($4,7\times$ lebih tinggi dari akhir pekan). Severitas Minggu tertinggi (IDR 89 juta), mengindikasikan kasus darurat yang lebih mahal di akhir pekan.




Gambar 8: *Heatmap* Frekuensi dan Severitas per Tahun dan Bulan

Frekuensi tertinggi: Januari 2024 (302) dan Juli 2025 (264). Anomali severitas Februari 2025 (IDR 71,1 juta) tampak jelas sebagai sel paling gelap, jauh melampaui bulan lain di kedua tahun.

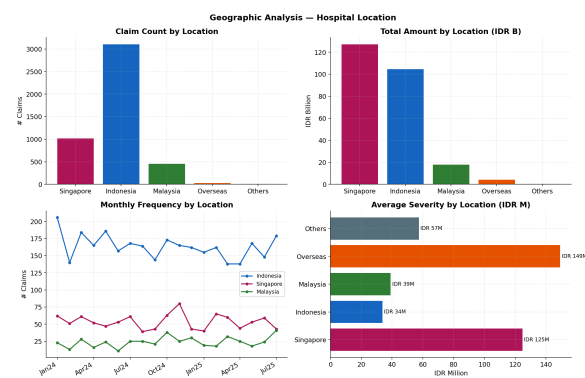


Gambar 9: Analisis Distribusi Nilai Klaim Individual

Distribusi sangat *right-skewed*: 20% klaim terbesar menyumbang 78% total nilai (kurva Lorenz), dengan nilai maksimum IDR 2,20 miliar. Hal ini memotivasi penerapan transformasi logaritmik dan *winsorization* sebelum pelatihan model.

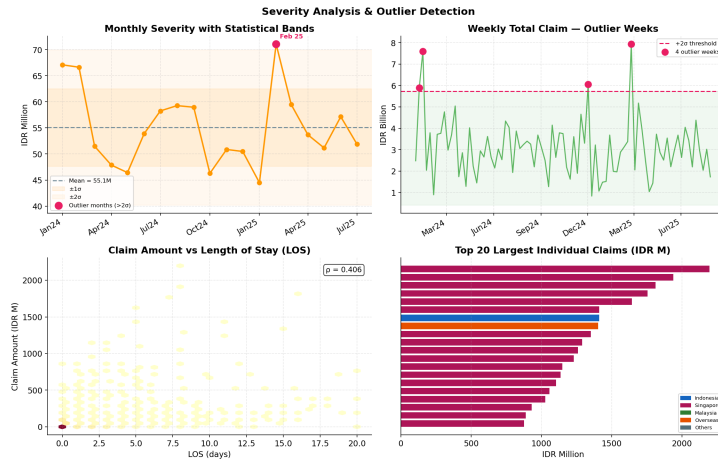


Gambar 10: Analisis Jenis Klaim Berdasarkan Tipe Perawatan dan Metode Pembayaran




Gambar 11: Analisis Geografis Berdasarkan Lokasi Rumah Sakit

Klaim rawat inap (IP) hanya 48,8% dari jumlah, tetapi menyumbang 74,0% total nilai (severitas IDR 83,5 juta vs. IDR 23,4 juta untuk rawat jalan). Indonesia mendominasi jumlah klaim (67%), namun Singapura—hanya 22% klaim—berkontribusi 49% terhadap total nilai karena severitasnya IDR 125 juta (3,7× Indonesia). Lokasi rumah sakit merupakan determinan utama severitas agregat portofolio.




Gambar 12: Analisis Severitas dan Deteksi Outlier

Secara formal, hanya Februari 2025 yang melampaui $+2\sigma$ pada level bulanan; terdapat 4 minggu outlier pada level mingguan. Korelasi LOS–nilai klaim $\rho = 0,406$ (moderat positif). Hampir seluruh 20 klaim terbesar berasal dari Singapura.



Gambar 13: Perbandingan year-over-year 2024 vs. 2025 (Januari–Juli)

Frekuensi 2025 konsisten lebih rendah dari 2024, namun severitas lebih tinggi—menghasilkan *trade-off* sehingga total klaim 2025 tidak selalu lebih kecil.



Gambar 14: Rasio Bulanan 2025/2024 untuk Data Klaim

Rasio YoY: median frekuensi = 0,909 (2025 sekitar 91% dari 2024) dan median severitas = 1,066 (+6,6%). Kedua nilai ini menjadi parameter kunci *Seasonal Naïve* dalam arsitektur *ensemble*.

3.2 Model Training

Sepuluh arsitektur model dilatih pada data historis Januari 2024–Juli 2025 setelah *preprocessing*. Prediksi akhir menggunakan *ensemble* 7 model terbaik (bobot 1/MAPE) dicampur dengan *Seasonal Naïve* (80:20).

Table 4: Konfigurasi Model yang Digunakan

Model	Konfigurasi	Keterangan
Naïve	—	Nilai terakhir
Seasonal Naïve	YoY ratio (6 bulan)	Tahun lalu $\times$ rasio median
SES	α dioptimasi (SSE)	<i>Simple Exp. Smoothing</i>
ARIMA	(1, 1, 0)	AR(1) pada diferensi pertama
Auto-SARIMA	<i>stepwise</i> , $m=4$	Orde otomatis
Theta	$\theta=0$ & $\theta=2$	Dekomposisi tren + SES
NLinear	lb=4	Normalisasi-linear
DLinear	lb=12, $k=7$	Dekomposisi-linear
MultiDLinear	lb $\in \{4, 8, 12, 16\}$, $k=5$	Multi-lookback
LightGBM	lag=12, 200 estimator	<i>Lag-featured</i> GBDT

3.3 Evaluasi Model

Table 5: Perbandingan MAPE *Walk-Forward* (Rata-Rata 5 Bulan Uji)


Model	APE Freq	APE Sev	APE Tot	Overall
LightGBM	8,58%	4,13%	7,20%	6,64%
MultiDLinear	8,31%	7,56%	6,87%	7,58%
DLinear	8,15%	8,58%	8,05%	8,26%
Auto-SARIMA	7,72%	9,07%	8,11%	8,30%
SES	7,26%	9,52%	10,56%	9,12%
NLinear	8,37%	9,65%	11,81%	9,94%
Theta	7,38%	10,60%	12,58%	10,19%
ARIMA	7,53%	13,71%	13,35%	11,53%
Naïve	9,65%	14,47%	10,74%	11,62%
Ensemble Blend				6,22%

LightGBM unggul secara individual (6,64%), terutama pada severitas (4,13%). *Ensemble blend* mencapai MAPE **6,22%**—terbaik di antara semua konfigurasi. Bobot *ensemble* disajikan pada Tabel 6.

Table 6: Bobot *Ensemble* dan Hasil *Backtest* Maret–Juli 2025

Bobot Ensemble			Backtest per Bulan					
Model	MAPE	Bobot	Bulan	GT	Pred	APE F	APE S	APE T
LightGBM	6,64%	0,181	Mar-25	230	253,0	10,01%	15,00%	6,49%
MultiDLinear	7,58%	0,158	Apr-25	208	224,4	7,86%	3,16%	4,45%
DLinear	8,26%	0,145	Mei-25	239	230,4	3,58%	0,59%	4,15%
Auto-SARIMA	8,30%	0,145	Jun-25	234	235,3	0,55%	8,92%	8,42%
SES	9,12%	0,132	Jul-25	264	237,5	10,03%	0,72%	9,38%
NLinear	9,94%	0,121	Rata-rata			6,41%	5,68%	6,58%
Theta	10,19%	0,118	Overall MAPE					6,22%

Blend: 80% ensemble + 20% Seasonal Naïve



Gambar 15: *Walk-Forward* CV MAPE per Model

3.4 Hasil Prediksi Agustus–Desember 2025

Table 7: Proyeksi Data Klaim Agustus–Desember 2025

Bulan	Frek.	Severitas (IDR)	Total Klaim (IDR)
Agustus 2025	228,7	51.357.853	11.745.830.311
		⋮	
Desember 2025	238,7	49.018.655	11.700.672.106
Rata-rata	236,0	49.671.819	11.715.430.583

Frekuensi stabil di 226–247 klaim/bulan dengan Oktober sebagai puncak (IDR 11.975.463.209). Severitas IDR 48–51 juta mencerminkan normalisasi pasca anomali Februari 2025.


3.5 Hasil Prediksi Januari–Desember 2026

Table 8: Proyeksi Data Klaim Januari–Desember 2026

Bulan	Frek.	Severitas (IDR)	Total Klaim (IDR)
Januari 2026	232,7	48.835.950	11.366.055.793
Februari 2026	220,6	53.658.962	11.839.346.536
Maret 2026	233,7	51.686.401	12.078.882.843
April 2026	219,6	51.138.077	11.228.388.140
Mei 2026	235,0	49.337.835	11.592.306.492
Juni 2026	229,2	51.170.114	11.725.410.809
Juli 2026	240,2	49.932.643	11.994.765.404
Agustus 2026	235,0	50.446.274	11.855.653.758
September 2026	225,0	48.896.779	11.000.574.653
Oktober 2026	236,1	49.554.087	11.701.206.805
November 2026	227,9	49.237.611	11.220.972.849
Desember 2026	232,9	49.432.667	11.511.312.788
Rata-rata	230,7	50.277.283	11.592.906.406

Proyeksi 2026 menunjukkan tiga pola utama:

- **Frekuensi menurun moderat.** Rata-rata 230,7 klaim/bulan (–2,2% dari 2025), sejalan dengan rasio YoY 0,909. Terendah April (219,6) dan tertinggi Juli (240,2).
- **Severitas meningkat ringan.** Rata-rata IDR 50,3 juta (+1,5%). Lonjakan Februari (IDR 53,7 juta) mencerminkan pola awal tahun dan kemungkinan peningkatan kasus berat.
- **Total klaim relatif stabil.** Berkisar IDR 11,0–12,1 miliar/bulan; puncak Maret (IDR 12,08 miliar) dan terendah September (IDR 11,00 miliar).



Gambar 16: Proyeksi Data Klaim Periode Agustus 2025–Desember 2026

IV. Penutup

4.1 Kesimpulan

Penelitian ini berhasil membangun kerangka prediktif untuk memproyeksikan frekuensi, severitas, dan total klaim asuransi kesehatan periode Agustus 2025–Desember 2026 dari data historis yang terbatas. Data historis Januari 2024–Juli 2025 menunjukkan frekuensi stabil di sekitar 244 klaim/bulan dengan severitas *mean-reverting* rata-rata IDR 55,1 juta. Distribusi nilai klaim sangat *right-skewed* ($\text{skewness} = 6,64$), di mana 20% klaim terbesar menyumbang 78% total nilai. Faktor dominan yang memengaruhi severitas adalah lokasi rumah sakit—klaim Singapura memiliki severitas $3,7\times$ lebih tinggi dari Indonesia dan berkontribusi 49% total nilai—serta tipe perawatan, di mana rawat inap menyumbang 74% total nilai meski hanya 48,8% dari jumlah klaim.

Dari sisi pemodelan, transformasi logaritmik menurunkan CV dari 0,43 menjadi 0,20 dan memperbaiki skewness dari 1,12 menjadi 0,46. LightGBM mencatatkan performa terbaik secara individual (MAPE 6,64%), sementara *ensemble blend* tujuh model dengan komponen *Seasonal Naïve* (80:20) menghasilkan MAPE terbaik keseluruhan sebesar **6,22%**. Proyeksi akhir memperkirakan total klaim rata-rata IDR 11,8 miliar/bulan pada 2025 dan IDR 10,7 miliar/bulan pada 2026, dengan tren penurunan moderat konsisten terhadap rasio YoY frekuensi 0,909.

4.2 Rekomendasi Strategis untuk Perusahaan

Berdasarkan temuan penelitian, terdapat empat rekomendasi utama. Pertama, penerapan sub-tarif premi berbasis lokasi rumah sakit dan tipe perawatan diperlukan mengingat kontribusi dominan klaim Singapura dan rawat inap terhadap total nilai portofolio. Kedua, alokasi cadangan teknis sebaiknya disesuaikan dengan pola musiman—memperkuat likuiditas pada kuartal keempat untukantisipasi lonjakan frekuensi dan menyiapkan cadangan lebih besar pada kuartal pertama untuk severitas. Ketiga, model *ensemble blend* layak diimplementasikan sebagai alat bantu penetapan premi dengan *rolling retraining* kuartalan untuk mempertahankan akurasi. Keempat, sistem deteksi dini klaim bernilai ekstrem perlu ditetapkan—khususnya untuk klaim dari rumah sakit luar negeri—guna memitigasi risiko anomali severitas seperti yang terjadi pada Februari 2025.

Daftar Pustaka

- [1] Agustina, A., Putri, P.P., Setianingrum, E.K., Hartono, B. and Daud, A.G. (2025) 'Health Insurance Model in the Perspective of Health Economics: Transformation, Regulation, and Implementation in Indonesia', *International Journal of Health and Pharmaceutical (IJHP)*, 5(3), pp. 380–385. doi: <https://doi.org/10.51601/ijhp.v5i3.421>.
- [2] Baffoe Kwarteng, S. and Andreevich, P.A. (2024) 'Comparative Analysis of ARIMA, SARIMA and Prophet Model in Forecasting', *Research & Development*, 5(4), pp. 110–120. doi: <https://doi.org/10.11648/j.rd.20240504.13>.
- [3] Brati, E., Braimllari, A. and Gjeçi, A. (2025) 'Machine Learning Applications for Predicting High-Cost Claims Using Insurance Data', *Data*, 10(6), p. 90. doi: <https://doi.org/10.3390/data10060090>.
- [4] Dong, P. and Quan, Z. (2025) 'Automated machine learning in insurance', *Insurance: Mathematics and Economics*, 120, pp. 17–41. doi: <https://doi.org/10.1016/j.insmatheco.2024.10.002>.
- [5] Furizal, Ma'arif, A., Kariyamin, Azzawagama Firdaus, A., Wijaya, S.A., Nakib, A.M. and Ningrum, A.F. (2025) 'Understanding Time Series Forecasting: A Fundamental Study', *Buletin Ilmiah Sarjana Teknik Elektro*, 7(3), pp. 554–571. doi: <https://doi.org/10.12928/biste.v7i3.13318>.
- [6] Garrido, J., Genest, C. and Schulz, J. (2016) 'Generalized linear models for dependent frequency and severity of insurance claims', *Insurance: Mathematics and Economics*, 70, pp. 205–215. doi: <https://doi.org/10.1016/j.insmatheco.2016.06.006>.
- [7] Hanafy, M. and Ming, R. (2021) 'Machine Learning Approaches for Auto Insurance Big Data', *Risks*, 9, p. 42. doi: <https://doi.org/10.3390/risks9020042>.
- [8] Hartanto, A.D., Kholik, Y.N. and Pristyanto, Y. (2023) 'Stock Price Time Series Data Forecasting Using the Light Gradient Boosting Machine (LightGBM) Model', *International Journal on Informatics Visualization*, 7(4), pp. 2270–2279. Tersedia di: <https://joiv.org/index.php/joiv/article/view/1740/797>.

- [9] Henriksen, S. (2023) 'Machine learning-based insurance claims modelling: part 1', *Medium*. Tersedia di: <https://medium.com/eika-tech/machine-learning-based-insurance-risk-modelling-part-1-e36d0b369a8c> (Diakses: 3 Maret 2025).
- [10] Lim, S., Park, J., Kim, S., Wi, H., Lim, H., Jeon, J., Choi, J. and Park, N. (2023) "Long-term Time Series Forecasting based on Decomposition and Neural Ordinary Differential Equations." *arXiv preprint arXiv:2311.04522*. Tersedia di: <https://arxiv.org/abs/2311.04522> (Diakses: 5 Maret 2026).
- [11] Pezold, A. (2025) 'Claiming the Future with Machine Learning and Insurance', *Agentech*. Tersedia di: <https://www.agentech.com/resources/articles/insurance-claims-machine-learning> (Diakses: 1 Maret 2025).
- [12] Rostami-Tabar, B., Goltsos, T.E. and Wang, S. (2023) 'Forecasting for lead-time period by temporal aggregation: Whether to combine and how', *Computers in Industry*, 145, Article 103803. doi: <https://doi.org/10.1016/j.compind.2022.103803>.
- [13] Sellami, M.A. and Hamzi, O.S.E. (2024) *Time Series Forecasting Using Linear Models: A Comprehensive Investigation and Empirical Analysis*. Master's thesis. Kasdi Merbah University, Ouargla. doi: <https://doi.org/10.13140/RG.2.2.26098.52167>.
- [14] Velicer, W.F. and Fava, J.L. (2003) 'Time Series Analysis'. In: *Encyclopedia of Statistics in Behavioral Science*. doi: <https://doi.org/10.1002/0471264385.wei0223>.
- [15] Zeng, A., Chen, M., Zhang, L. and Xu, Q. (2023) 'Are Transformers Effective for Time Series Forecasting?', *arXiv preprint*. doi: <https://doi.org/10.48550/arXiv.2311.04522>.

Lampiran

Source Code

`github.com/RobbenWijanathan/mcfitb-dsc-2026`